




Karush-Kuhn-Tucker (KKT)条件



Eureka

关注他

[来自专栏 · Eureka机器学习读书笔记 >](#)

3353 人赞同了该文章 >

[专栏文章汇总](#)

文章结构如下：

- 1: 等式约束优化问题
- 2: 不等式约束优化问题
- 3: 一个例子

注：本文来自台湾周志成老师《线性代数》及其博客

Karush-Kuhn-Tucker (KKT)条件是**非线性规划***(nonlinear programming)最佳解的必要条件。KKT条件将Lagrange乘数法(Lagrange multipliers)所处理涉及等式的约束优化问题推广至不等式。在实际应用上，KKT条件(方程组)一般不存在代数解，许多优化算法可供数值计算选用。这篇短文从Lagrange乘数法推导KKT条件并举一个简单的例子说明解法。

关于作者



Eureka

回答

1

文章

46

关注者

9,668

关注他

发私信



1: 等式约束优化问题

▲ 赞同 3353 ▼

● 141 条评论

🔗 分享

♥ 喜欢

★ 收藏

📄 申请转载

...

$$\begin{aligned} \min \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & g(\mathbf{x}) = 0. \end{aligned}$$

为方便分析, 假设 f 与 g 是连续可导函数。Lagrange乘数法是等式约束优化问题的典型解法。定义Lagrangian函数

$$L(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda g(\mathbf{x})$$

其中 λ 称为Lagrange乘数。Lagrange乘数法将原本的约束优化问题转换成等价的无约束优化问题

$$\min_{\mathbf{x}, \lambda} L(\mathbf{x}, \lambda)$$

计算 L 对 $\mathbf{x}$ 与 λ 的偏导数并设为零, 可得最优解的必要条件:

$$\begin{aligned} \nabla_{\mathbf{x}} L &= \frac{\partial L}{\partial \mathbf{x}} = \nabla f + \lambda \nabla g = \mathbf{0} \\ \nabla_{\lambda} L &= \frac{\partial L}{\partial \lambda} = g(\mathbf{x}) = 0 \end{aligned}$$

其中第一式为定常方程式(stationary equation), 第二式为约束条件。解开上面 $n + 1$ 个方程式可得 $L(\mathbf{x}, \lambda)$ 的stationary point $\mathbf{x}^*$ 以及 λ 的值(正负数皆可能)。

2: 不等式约束优化问题

接下来我们将约束等式 $g(\mathbf{x}) = 0$ 推广为不等式 $g(\mathbf{x}) \leq 0$ 。考虑这个问题

$$\begin{aligned} \min \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & g(\mathbf{x}) \leq 0. \end{aligned}$$

约束不等式 $g(\mathbf{x}) \leq 0$ 称为原始可行性⁺(primal feasibility), 据此我们定义可行域(feasible region) $K = \{\mathbf{x} \in \mathbb{R}^n | g(\mathbf{x}) \leq 0\}$ 。假设 $\mathbf{x}^*$ 为满足约束条件的最佳解, 分开两种情况讨论:

(1) $g(\mathbf{x}^*) < 0$, 最佳解位于 K 的内部, 称为内部解(interior solution), 这时约束条件是无效的(inactive);

(2) $g(\mathbf{x}^*) = 0$, 最佳解落在 K 的边界, 称为边界解(boundary solution), 此时约束条件是有效的(active)。

这两种情况的最佳解具有不同的必要条件。

(1)内部解: 在约束条件无效的情形下, $g(\mathbf{x})$ 不起作用, 约束优化问题退化为无约束优化问题, 因此驻点 $\mathbf{x}^*$ 满足 $\nabla f = \mathbf{0}$ 且 $\lambda = 0$ 。

(2)边界解: 在约束条件有效的情形下, 约束不等式变成等式 $g(\mathbf{x}) = 0$, 这与前述Lagrange乘数法的情况相同。我们可以证明驻点 $\mathbf{x}^*$ 发生于 $\nabla f \in \text{span} \nabla g$, 换句话说, 存在 λ 使得 $\nabla f = -\lambda \nabla g$ 。但这里 λ 的正负号是有其意义的。因为我们希望最小化 f 。梯度 ∇f (函数 f 在点 $\mathbf{x}$ 的)

因此，不论是内部解或边界解， $\lambda g(\mathbf{x}) = 0$ 恒成立，称为**互补松弛性**⁺(complementary slackness)。整合上述两种情况，最佳解的必要条件包括Lagrangian函数 $L(\mathbf{x}, \lambda)$ 的定常方程式、原始可行性、对偶可行性，以及互补松弛性：

$$\begin{aligned}\nabla_{\mathbf{x}} L &= \nabla f + \lambda \nabla g = \mathbf{0} \\ g(\mathbf{x}) &\leq 0 \\ \lambda &\geq 0 \\ \lambda g(\mathbf{x}) &= 0.\end{aligned}$$

这些条件合称为Karush-Kuhn-Tucker (KKT)条件。如果我们要最大化 $f(\mathbf{x})$ 且受限于 $g(\mathbf{x}) \leq 0$ ，那么对偶可行性要改成 $\lambda \leq 0$ 。

上面结果可推广至多个约束等式与约束不等式的情况。考虑标准约束优化问题(或称非线性规划)：

$$\begin{aligned}\min \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & g_j(\mathbf{x}) = 0, \quad j = 1, \dots, m, \\ & h_k(\mathbf{x}) \leq 0, \quad k = 1, \dots, p.\end{aligned}$$

定义Lagrangian 函数

$$L(\mathbf{x}, \{\lambda_j\}, \{\mu_k\}) = f(\mathbf{x}) + \sum_{j=1}^m \lambda_j g_j(\mathbf{x}) + \sum_{k=1}^p \mu_k h_k(\mathbf{x})$$

其中 λ_j 是对应 $g_j(\mathbf{x}) = 0$ 的Lagrange乘数， μ_k 是对应 $h_k(\mathbf{x}) \leq 0$ 的Lagrange乘数(或称KKT乘数)。KKT条件包括

$$\begin{aligned}\nabla_{\mathbf{x}} L &= \mathbf{0} \\ g_j(\mathbf{x}) &= 0, \quad j = 1, \dots, m, \\ h_k(\mathbf{x}) &\leq 0, \\ \mu_k &\geq 0, \\ \mu_k h_k(\mathbf{x}) &= 0, \quad k = 1, \dots, p.\end{aligned}$$

注：感谢评论区 追梦的lin 提出，在使用KKT条件时需要满足**Regularity conditions**⁺ (or constraint qualifications)，维基在第三部分有了介绍：[Karush-Kuhn-Tucker conditions](#)。比较常见的是Linearity constraint qualification (LCQ)，即约束条件是仿射函数。

3：一个例子

考虑这个问题

$$\begin{aligned}\min \quad & x_1^2 + x_2^2, \\ \text{s.t.} \quad & x_1 + x_2 = 1 \\ & x_2 \leq \alpha,\end{aligned}$$

其中 $(x_1, x_2) \in \mathbb{R}^2$ ， α 为实数。写出Lagrangian函数

$$L(x_1, x_2, \lambda, \mu) = x_1^2 + x_2^2 + \lambda(1 - x_1 - x_2) + \mu(x_2 - \alpha)$$

$$\begin{aligned}\frac{\partial L}{\partial x_i} &= 0, \quad i = 1, 2, \\ x_1 + x_2 &= 1 \\ x_2 - \alpha &\leq 0 \\ \mu &\geq 0 \\ \mu(x_2 - \alpha) &= 0.\end{aligned}$$

求偏导可得 $\frac{\partial L}{\partial x_1} = 2x_1 - \lambda = 0$ 且 $\frac{\partial L}{\partial x_2} = 2x_2 - \lambda + \mu = 0$ ，分别解出 $x_1 = \frac{\lambda}{2}$ 且 $x_2 = \frac{\lambda}{2} - \frac{\mu}{2}$ 。代入约束等式 $x_1 + x_2 = \lambda - \frac{\mu}{2} = 1$ 或 $\lambda = \frac{\mu}{2} + 1$ 。合并上面结果，

$$x_1 = \frac{\mu}{4} + \frac{1}{2}, \quad x_2 = -\frac{\mu}{4} + \frac{1}{2}$$

最后再加入约束不等式 $-\frac{\mu}{4} + \frac{1}{2} \leq \alpha$ 或 $\mu \geq 2 - 4\alpha$ 。底下分开三种情况讨论。

(1) $\alpha > \frac{1}{2}$ ：不难验证 $\mu = 0 > 2 - 4\alpha$ 满足所有的KKT条件，约束不等式是无效的， $x_1^* = x_2^* = \frac{1}{2}$ 是内部解，目标函数的极小值是 $\frac{1}{2}$ 。

(2) $\alpha = \frac{1}{2}$ ：如同1， $\mu = 0 = 2 - 4\alpha$ 满足所有的KKT条件， $x_1^* = x_2^* = \frac{1}{2}$ 是边界解，因为 $x_2^* = \alpha$ 。

(3) $\alpha < \frac{1}{2}$ ：这时约束不等式是有效的， $\mu = 2 - 4\alpha > 0$ ，则 $x_1^* = 1 - \alpha$ 且 $x_2^* = \alpha$ ，目标函数的极小值是 $(1 - \alpha)^2 + \alpha^2$ 。

4: 参考文献

周志成：《线性代数》，国立交通大学出版社

Karush-Kuhn-Tucker (KKT) 条件

所属专栏 · 2020-06-07 03:22 更新



Eureka机器学习读书笔记

Eureka

42 篇内容 · 18133 赞同

订阅

最热内容 · 马尔可夫链蒙特卡罗算法 (MCMC)

编辑于 2018-06-19 15:29

最优化 机器学习 数学



理性发言，友善互动

141 条评论

默认 最新



LiuJ

看了那么多关于KKT条件的介绍，发现这个是最简洁、最清楚的

2019-10-01