

$\exists c > 0$, 每个 Gaussian 变量 $X_i \sim N(\mu_i, \sigma_i^2)$ 满足 $E(X) = \mu$, 对 $t > 0$ $P(|X - \mu| > t) < c \cdot e^{-\frac{t^2}{2\sigma^2}}$ (盖住)

中间的不管, 尾分布指数下降

大数据算法-2024 春

Lecture 2: 集中不等式、Chaining

2024.2.29

Lecturer: 丁虎

Gaussian

Subgaussian

Scribe: 王运韬

$$P((1-\delta)\mu < S < (1+\delta)\mu) < 1 - e^{-\frac{\delta^2 \mu^2}{n}}$$

1 集中不等式

gaussian: 正态分布

$$\frac{1}{\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$\Pr[X - \mu > t]$

指数下降

Chernoff 界可以扩展到任何次高斯 (subgaussian) 随机变量。

Definition 1.1. 随机变量被称为次高斯随机变量, 如果存在 $c > 0, \sigma$, 使得对充分大的 $t, \mathbb{P}(x \geq t) \leq ce^{-\frac{t^2}{2\sigma^2}}$.

0,1 分布为 subgaussian

Example 1.2. 支撑集为闭区间 (或其他 $\mathbb{R}^d$ 上紧集) 的连续分布. 原因是在一个区间内有界而他处为 0.

Definition 1.3. 对次高斯随机变量, 可以定义范数 [2]: $\|x\|_{sg} = \inf_{s>0} \mathbb{E}[e^{\frac{x^2}{s^2}}] \leq 2 \rightarrow$ 常数.

norm $(x-\mu)^2$ 取值 用 Markov $x \sim N(\mu, \sigma^2)$ 不等式 $\|x\|_{sg} = O(\sigma)$

X 分布 (集中程度)

在机器学习等任务中, 时常需要计算数据的统计量, 如均值、最大值等。受限于巨量数据, 难以精确计算。故而可以使用集中不等式来估计。

Theorem 1.4 (次高斯分布的 Hoeffding 界). $x_1, x_2, \dots, x_n$ 是独立的次高斯随机变量. 均值皆为 0. 则有

$$\mathbb{P}\left(\left|\sum_1^n x_i\right| \geq t\right) \leq 2e^{-\frac{2t^2}{\sum \|x_i\|_{sg}^2}}$$

$\int_{-\infty}^{\infty} e^{-\frac{(x-\mu)^2}{s^2}} f(x) dx$

inf 下界 ≤ 2

集中

Example 1.5. 若 $X_i \in [a_i, b_i]$, 则有

$$\mathbb{P}\left(\left|\sum_1^n (x_i - \mathbb{E}X_i)\right| \geq t\right) \leq 2e^{-\frac{2t^2}{\sum (b_i - a_i)^2}}$$

Remark 1.6. 事实上, 上式对任意随机变量都成立, 并不局限于次高斯变量。

接下来我们引入一个有用的概念。

Definition 1.7 (鞅). 对于随机变量序列 $z_1, z_2, \dots$, 有

$$\mathbb{E}[z_j | z_1, z_2, \dots, z_{j-1}] = (/ \leq / \geq) z_{j-1}, \quad \forall j \in \mathbb{N}.$$

则称之为一个鞅 (martingale)/下鞅 (submartingale)/上鞅 (supermartingale) 序列.

Example 1.8. 一个人参加一系列赌博游戏, 每次游戏带来的收益均值都为 0. 则此人的本金 (构成的序列) 是一个鞅.

Theorem 1.9 (Azuma 不等式). 对于上述的鞅/下鞅, 如满足 $\forall i, z_i - z_{i-1} \in [a_i, b_i], |a_i - b_i| \leq c_i$, 则

$$\mathbb{P}(z_j - z_0 \leq -t) \leq e^{-\frac{t^2}{\sum c_i^2}}$$

Proof.

$$\begin{aligned}
\mathbb{P}(z_j - z_0 \leq -t) &= \mathbb{P}\left(\sum_{i=1}^j (z_{i-1} - z_i) \geq t\right) \\
&\leq e^{-\lambda t} \mathbb{E}[e^{\lambda \sum_{i=1}^j (z_{i-1} - z_i)}] \quad \leftarrow \text{Markov} \\
&= e^{-\lambda t} \mathbb{E}\left[\mathbb{E}[e^{\lambda \sum_{i=1}^j (z_{i-1} - z_i)} | z_{j-1}, \dots, z_1]\right] \quad \leftarrow \\
&= e^{-\lambda t} \mathbb{E}\left[e^{\lambda \sum_{i=1}^{j-1} (z_{i-1} - z_i)} \mathbb{E}[e^{\lambda(z_{j-1} - z_j)} | z_{j-1}, \dots, z_1]\right] \\
&= e^{-\lambda t} \mathbb{E}\left[e^{\lambda \sum_{i=1}^{j-1} (z_{i-1} - z_i)} \mathbb{E}[e^{\lambda(\mathbb{E}[z_j] - z_j)} | z_{j-1}, \dots, z_1]\right] \quad \leftarrow \text{鞅的定义} \\
&\leq e^{-\lambda t} \mathbb{E}\left[e^{\lambda \sum_{i=1}^{j-1} (z_{i-1} - z_i)} e^{-\lambda^2 \frac{(b_j - a_j)^2}{8}} | z_{j-1}, \dots, z_1\right] \quad \leftarrow \text{(上节课讲义中的 Hoeffding 引理)} \\
&\leq e^{-\lambda t} e^{-\frac{\lambda^2 \sum_i (b_i - a_i)^2}{8}} \\
&\leq e^{-\frac{t^2}{\sum_i c_i^2}}
\end{aligned}$$

$e^{\lambda x} \leq \frac{\lambda^2 (b_j - a_j)^2}{8}$ (递推)
 (优化 λ)

Remark 1.10. 同理可证 $\mathbb{P}(z_j - z_0 \geq t) \leq e^{-\frac{t^2}{\sum c_i^2}}$

2 Chaining

上述集中不等式提供了随机变量均值的尾概率, 要研究一族随机变量的上界 (同样是随机变量) 的尾概率, 我们引入 Chaining 方法. 以下我们研究一个具体的案例, 从中管窥 chaining 方法的一角. 更多应用参见 [1].

$$① x_1, \dots, x_n \in [0, 1]$$

$$P\left[\max_{1 \leq i \leq n} x_i \leq 0.8\right] = 0.8^n$$

$$P\left[\max_{1 \leq i \leq n} x_i > 0.8\right] = 1 - 0.8^n$$

$$② t_1 = \frac{1}{n} \quad t_2 = \frac{2}{n} \quad \dots \quad t_i = \frac{i}{n} \quad t_n = 1$$

$x_i = f(t_i)$ 为 $[0, 1]$ 上随机变量

$$\forall t, t' \in [0, 1] \quad |f(t) - f(t')| \leq \frac{1}{2} |t - t'|$$

$$P\left(\max_{1 \leq i \leq n} x_i > 0.8\right) \leq \underbrace{1 - \left(0.8 - \frac{1}{2n}\right)^{\frac{n}{2}}}_{\text{发生概率上界更优}} < 1 - 0.8^n$$

发生概率上界更优

$$③ x = f(t) \quad \text{最小间隔 } \frac{1}{2} \hookrightarrow n$$

$$P\left(\max_{1 \leq i \leq n} x_i > 0.8\right) \leq 1 - (0.8 - 2\varepsilon)^{\frac{1}{2\varepsilon}}$$

1) f 的平滑性

$$② t \in D \quad D \subseteq [0, 1]$$

$$④ = \text{层 } \varepsilon\text{-net}$$

$$- \text{层 } \varepsilon\text{-net} \quad \text{第一层 } f(i \cdot 2\varepsilon) < 0.8 - 2\varepsilon + \underline{\underline{\delta}}$$

$$= \text{层 } \varepsilon^2\text{-net} \quad \text{第二层 } f(i \cdot 2\varepsilon + j \cdot 2\varepsilon^2) \leq 0.8 - 2\varepsilon^2$$

$$(0, 0.8 + \delta)$$

Chaining

多层网络
减少上界

ε -网 度量

假设我们被给定了一族有界向量 $T \subset \mathbb{R}^n$, 其在 X 范数下的直径为 $\rho_X(T)$. 又有随机向量 $g \in \mathbb{R}^n$ 的每一项都是独立的标准高斯分布 (均值为 0, 方差为 1). 我们研究 $(X_t)_{t \in T}, X_t := \langle g, t \rangle$. 利用正态分布线性组合均值、方差的性质, 可以算出

$$\forall s, t \in T, \mathbb{P}(|X_s - X_t| > \lambda) \lesssim e^{-\lambda^2 / (2\|s-t\|_2^2)}. \quad (1)$$

上式中, $\lesssim$ 表示右端乘以某常数 c 后 $\leq$ 成立. 接下来, 我们展示三种计算 $g(T) := \mathbb{E}_g \sup_{t \in T} X_t$ 的尾分布的方法.

2.1 方法一: 合并界 (Union bound)

回顾概率论的知识, 我们有:

$$\mathbb{E}|Z| = \int_0^\infty \mathbb{P}(Z > u) du.$$

从而

$$\begin{aligned} \mathbb{E} \sup_{t \in T} X_t &= \int_0^\infty \mathbb{P}(\sup_{t \in T} X_t > u) du \\ &\leq \int_0^{\rho_{\ell_2}(T) \sqrt{2 \log |T|}} \overbrace{\mathbb{P}(\sup_{t \in T} X_t > u)}^{\leq 1} du + \int_{\rho_{\ell_2}(T) \sqrt{2 \log |T|}}^\infty \mathbb{P}(\sup_{t \in T} X_t > u) du \\ &\leq \rho_{\ell_2}(T) \sqrt{2 \log |T|} + \int_{\rho_{\ell_2}(T) \sqrt{2 \log |T|}}^\infty \sum_{t \in T} \mathbb{P}(X_t > u) du \quad (\text{合并界}) \\ &\leq \rho_{\ell_2}(T) \sqrt{2 \log |T|} + |T| \cdot \int_{\rho_{\ell_2}(T) \sqrt{2 \log |T|}}^\infty e^{-u^2 / (2\rho_{\ell_2}(T)^2)} du \\ &= \rho_{\ell_2}(T) \sqrt{2 \log |T|} + \rho_{\ell_2}(T) \cdot |T| \cdot \int_{\sqrt{2 \log |T|}}^\infty e^{-\nu^2 / 2} d\nu \quad (\text{变量代换}) \\ &\lesssim \rho_{\ell_2}(T) \cdot \sqrt{\log |T|} \end{aligned} \quad (2)$$

2.2 方法二: ϵ -网 ϵ -net 构造 ϵ -net

设 $T' \subseteq T$ 为 T 的 ϵ -网, 定义为满足对任意 $t \in T$ 都存在 $t' \in T'$ 使得 $\|t - t'\|_2 \leq \epsilon$ 的集合. 由 $\langle g, t \rangle = \langle g, t' + (t - t') \rangle$, 有


$$X_t = X_{t'} + X_{t-t'}.$$

从而

$$g(T) \leq g(T') + \mathbb{E} \sup_{t \in T} \langle g, t - t' \rangle.$$

最大 ϵ -net 的 size
被称为 D 的 covering number

3



由(2), $g(T') \lesssim \rho_{\ell_2}(T') \cdot \sqrt{\log |T'|} \leq \rho_{\ell_2}(T) \cdot \sqrt{\log |T'|}$. 又有 $\langle g, t-t' \rangle \leq \|g\|_2 \cdot \|t-t'\| \leq \varepsilon \|g\|_2$, 以及

$$\mathbb{E}\|g\|_2 \leq (\mathbb{E}\|g\|_2^2)^{1/2} \leq \sqrt{n}.$$

上式第一个不等号将 $\|g\|_2 * 1$ 视作两项的乘积, 作积分的 Cauchy-Schwarz 不等式, 第二个不等号源于直接计算. 得出:

$$\begin{aligned} g(T) &\leq \rho_{\ell_2}(T) \cdot \sqrt{\log |T'|} + \varepsilon \sqrt{n} \\ &= \rho_{\ell_2}(T) \cdot \log^{1/2} \mathcal{N}(T, \ell_2, \varepsilon) + \varepsilon \sqrt{n} \end{aligned} \quad (3)$$

此处 $\mathcal{N}(T, d, u)$ 表示度量熵 (metric entropy) 或覆盖数 (covering number), 定义为 d -度量空间中使用半径为 u 的球覆盖 T 所需的最小个数. 易见这即为 u -网大小的下确界. 可以通过优化(3)中的参数 ε 来得出更精细的界. 不论如何, 比起(2), 至少这一上界对于 T 为无穷集的情形不再平凡了.

2.3 方法三: Dudley 不等式 (Chaining)

Chaining 的核心思想是, 使用越来越细密, 乃至可数多个网, 来减小上界. 设 $T_r \subset T$ 为 T 的 $2^{-r} \rho_{\ell_2}(T)$ -网, 其覆盖半径记为 ϵ_r , t_r 是 T_r 中距离 t 最近的点. 则有

$$\langle g, t \rangle = \langle g, t_0 \rangle + \sum_{r=1}^{\infty} \langle g, t_r - t_{r-1} \rangle$$

这是因为 t_r 距离 t 趋于零.

$$\begin{aligned} g(T) &\leq \sum_{r=1}^{\infty} \mathbb{E} \sup_{t \in T} \langle g, t_r - t_{r-1} \rangle \\ &\lesssim \sum_{r=1}^{\infty} \frac{\rho_{\ell_2}(T)}{2^r} \cdot \log^{1/2} (\mathcal{N}(T, \ell_2, \frac{\rho_{\ell_2}(T)}{2^r})^2) \quad (\text{由 (2) 及三角不等式}) \\ &\lesssim \sum_{r=1}^{\infty} \frac{\rho_{\ell_2}(T)}{2^r} \cdot \log^{1/2} \mathcal{N}(T, \ell_2, \frac{\rho_{\ell_2}(T)}{2^r}). \end{aligned} \quad (4)$$

在此对 (4) 做一解释: 由三角不等式, 可知 $\|t_r - t_{r-1}\|$ 不超过 $\epsilon_r + \epsilon_{r-1}$, 注意到 $|T_r - T_{r-1}| \leq |T_r| \cdot |T_{r-1}| \leq |T_r|^2$, T_r 选为最小的 ϵ_r -网, 直接利用合并界 (2) 即可.

同学们可以尝试将 T 取成欧氏空间内的单位球或方块, 具体计算一下. 将会发现通过 Chaining 得到的界更优.

References

- [1] J. Nelson. *Chaining introduction with some computer science applications*. Bulletin of EATCS 3, no. 120, 2016.
- [2] R. Vershynin. *Concentration of Sums of Independent Random Variables*, page 11–37. Cambridge Series in Statistical and Probabilistic Mathematics. Cambridge University Press, 2018.