

Principal Component Analysis

大数据算法-2024 春

Lecture 6: 数据降维之主成分分析


2024.3.12

Lecturer: 丁虎

Scribe: 王运韬

$$\sum_{i=1}^n \|p_i - \pi(p_i)\| \quad \text{or} \quad \min \max \|p_i - \pi(p_i)\|$$

复杂度更高



对于高维数据集，数据经常是非常稀疏的，一个合理的操作是把这些高维数据降为低维数据。

投影到 k 维超平面

从几何的角度来说，对于集合 $P = \{p_1, \dots, p_n\} \subset R^d$ ，我们期望找到一个 k 维的子空间 E ， $k \ll d$ ，最小化 $\sum_{i=1}^n \|p_i - \pi(p_i)\|_2^2$ ，其中 π 是 R^d 到 E 的投影。当然，此处的目标函数也可以替换为其他的度量。

$$\pi: R^d \rightarrow E$$

PCA 非凸有解析解

从线性代数的角度讲，对于矩阵 $A \in R^{n \times d}$ 找到一个秩为 k 的矩阵 A_k 使得 $\|A - A_k\|_F$ 最小。其中 $\|X\|_F = \sqrt{\sum_{i,j} X_{ij}^2}$ 。

Frobenious Norm

当 $k = 0$ ，我们要寻找的是一个点，由定义可知就是 P 的重心 $\nu(P)$ 。当 $k > 0$ ， $\nu(P)$ 应还是在我们要寻找的子空间上：

$$A = \begin{pmatrix} p_1^T \\ \vdots \\ p_n^T \end{pmatrix}$$

$$A_k = \begin{pmatrix} \pi(p_1^T) \\ \vdots \\ \pi(p_n^T) \end{pmatrix}$$

$$\sum_{i=1}^n \|p_i - \text{proj}_E(\nu(P))\|_2^2 = \sum_{i=1}^n \|\text{proj}_E(p_i) - \text{proj}_E(\nu(P))\|_2^2 + \|\text{proj}_E(p_i) - p_i\|_2^2$$

$$\leq \|\text{proj}_E(p_i) - \text{proj}_E(\nu(P))\|_2^2 + \|p_i - \text{proj}_E(p_i)\|_2^2 + \|\nu(P) - \text{proj}_E(\nu(P))\|_2^2$$
$$= \|p_i - \nu(P)\|_2^2.$$

$$\nu(P) = \frac{1}{|P|} \sum P$$

由重心的定义，可知不等号只能相等，即 $\nu(P) \in E$ 。



1 奇异值分解 (Singular Value Decomposition)

根据上边的表述，我们可以把 PCA 的核心思想表述为：能否找到更小的一组基底，使之能尽可能好地重新代表原数据？为了严格地解决这个问题，我们引入奇异值分解技术。 X 为 $n \times m$ 矩阵， $X^T X$ 秩为 r ，接下来我们定义相关的量：


- $\{\hat{v}_1, \hat{v}_2, \dots, \hat{v}_r\}$ 是 $X^T X$ 一族正交的 $m \times 1$ 特征向量，对应特征值 $\{\lambda_1, \lambda_2, \dots, \lambda_r\}$ 。即

$$(X^T X) \hat{v}_i = \lambda_i \hat{v}_i.$$

$$A \vec{x} = \lambda \vec{x}$$

- $\sigma_i \equiv \sqrt{\lambda_i}$ 正实数特征值。

↓ $k=1$ 时



补空间

即 $\langle F, F^\perp \rangle = 0$

$$\|p_i - \pi(p_i)\| = \|\alpha(p_i) - \alpha(\pi(p_i))\|$$

↓ Σ

$$\sum \|p_i - \pi(p_i)\| = \sum \|\alpha(p_i) - \alpha(\pi(p_i))\|$$

n 维 $\rightarrow n-1$ 维

1 维 $\rightarrow 0$ 维

必经过重心 $\alpha(\mu)$

线性 $\mu \mapsto \alpha(\mu)$ 原 1 维空间
必经过 μ

$$A = n \begin{pmatrix} d \\ \vdots \end{pmatrix} = \begin{pmatrix} u \\ \vdots \end{pmatrix} \underset{n \times d}{S} \begin{pmatrix} v \\ \vdots \end{pmatrix} \underset{d \times d}{} \quad \text{原 } 1 \text{ 维空间}$$

$n \times d$

$n \times n$

U, V 单位正交矩阵

$$U \cdot U^T = \begin{pmatrix} 1 & & \\ & \ddots & \\ & & 1 \end{pmatrix}$$

• $\{\hat{u}_1, \hat{u}_2, \dots, \hat{u}_r\}$ 是一族 $n \times 1$ 向量, 满足 $\hat{u}_i \equiv \frac{1}{\sigma_i} X \hat{v}_i$.

$$\hat{u}_i \cdot \hat{u}_j = \begin{cases} 1 & \text{如果 } i = j \\ 0 & \text{otherwise} \end{cases}$$

$$\|X \hat{v}_i\| = \sigma_i$$

我们的目标是构造如下的对角矩阵 Σ .

$$\Sigma \equiv \begin{bmatrix} \sigma_1 & & & & 0 \\ & \ddots & & & \\ & & \sigma_r & & \\ & 0 & & 0 & \\ 0 & & & & \ddots \\ & & & & & 0 \end{bmatrix}$$

其中 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r$ 是由大到小排列的奇异值. 我们需要构造正交矩阵

$$V = [\hat{v}_1 \ \hat{v}_2 \ \dots \ \hat{v}_m]$$

$$U = [\hat{u}_1 \ \hat{u}_2 \ \dots \ \hat{u}_n]$$

此处增补了 $(m-r)$ 和 $(n-r)$ 个正交基来使 V 和 U 为方阵. 满足

$$X = U \Sigma V^T \quad (1)$$

根据需求, 可以发现如下奇异值分解矩阵 X 的算法:

1. 计算 XX^T 的特征值和特征向量, 用单位化的特征向量构成 U .
2. 计算 $X^T X$ 的特征值和特征向量, 用单位化的特征向量构成 V .
3. 将 XX^T 的特征值开方, 得到 Σ .

当然, 因为计算 XX^T 的开销可能很大, 这个算法不是实践中使用的算法. 此外, 在固定了 Σ 对角元的排序后, 奇异值分解是唯一的.

$$A = U \Sigma V^T$$

$$V^T V = I$$

$$\begin{aligned} A \cdot A^T &= U \Sigma V^T V \Sigma^T U^T \\ &= U \Sigma \cdot \Sigma^T U^T \end{aligned}$$

$$A \cdot A^T \cdot U = U \begin{pmatrix} \sigma_1^2 & & \\ & \ddots & \\ & & \sigma_r^2 \\ & & & 0 \end{pmatrix}$$


$k=1$ 时 ★

$$= U \begin{pmatrix} \sigma_1 & & & \\ & \ddots & & \\ & & \sigma_n & \\ & & & 0 \end{pmatrix} U^T$$

✓
 $A\vec{x} = \lambda \vec{x}$
特征向量 u ★

fixed.

$$\|p_i\|^2 = \|p_i - \pi(p_i)\|^2 + \|\langle p_i, t_1 \rangle\|^2$$



PCA $\Rightarrow \max \|\langle p_i, t_1 \rangle\|^2$

$$= \|A \cdot t_1\|_F^2$$

$$A \cdot t_1 = U \cdot S \cdot V^T \cdot t_1$$

单位
特征向量

t_1 方向

↓
 $(\sigma_1 \vec{u}_1, \sigma_2 \vec{u}_2, \dots, \sigma_d \vec{u}_d)$
只有 d 个有值

$V^T t_1$
 $d \times d \quad d \times 1$

线性组合

$V \in \mathbb{R}^{d \times d}$

$$= x_1 \sigma_1 u_1 + x_2 \sigma_2 u_2 + \dots + x_d \sigma_d u_d$$

$u_1, \dots, u_d$ - 组正交基

d 维

$$\|A t_1\|^2 = x_1^2 \sigma_1^2 + x_2^2 \sigma_2^2 + \dots + x_d^2 \sigma_d^2$$

$V^T t_1 \stackrel{\text{def}}{=} \begin{pmatrix} x_1 \\ \vdots \\ x_d \end{pmatrix}$

单位向量

有 $x_1^2 + x_2^2 + \dots + x_d^2 = 1$

有 $\sigma_1 > \sigma_2 > \dots > \sigma_d$

$$\Rightarrow V^T t_1 = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \\ 0 \end{pmatrix}$$

$$V^T = [V_1^T \dots V_n^T]$$

$t_1 = V_1$ ★

最大奇异值对应 $\vec{v}$ ★

即为所求 $\vec{t}$

(3) $k > 1$ 时, 假设 u 为原点 重心.

$$F = \text{span} \{t_1, t_2, \dots, t_k\}$$

$$\min \sum_{i=1}^n \|p_i - \pi(p_i)\|^2 \Leftrightarrow \max \sum_{i=1}^n (\langle p_i, t_1 \rangle^2 + \langle p_i, t_2 \rangle^2 + \dots + \langle p_i, t_n \rangle^2)$$


一维情况推广

(k 项)

结果为 $t_1 = v_1 \quad t_2 = v_2 \quad \dots \quad t_k = v_k$

限定 $t_1 = \frac{\pi(v_1)}{\|\pi(v_1)\|}$

| 标准正交基第一个向量可自由选取)
与 $t_2, \dots, t_k$ 正交.



按 $F^\perp$ 旋转

$\langle p_i, t_2 \rangle \dots \langle p_i, t_n \rangle$ 不变

↓ 一维问题

$$\max \sum_{i=1}^n \langle p_i, t_1 \rangle^2$$

↳ $k=1$ 时有 $t_1 = v_1$

同理递推 $t_2 = v_2 \dots t_n = v_n$

$$A_k = A(t_1 \dots t_k)$$

$$= A(v_1 \dots v_k)$$

$$n \times d \quad d \times k$$

$$\rightarrow n \times k$$

正交空间

2 主成分分析

回顾我们的设定, 原始数据可以写成 $X \in \mathbb{R}^{n \times d}$, n 是样本个数, d 是特征维数。假设我们之前假设的 k 维子空间 E 有一组标准正交基 $v_1, v_2, \dots, v_k$, 并将它扩展到 d 维全空间, 那么对于任意的向量 a ,

$$\|a - \text{proj}_E(a)\|^2 = \left\| \sum_{j=1}^d v_j \langle a, v_j \rangle - \sum_{j=1}^k v_j \langle a, v_j \rangle \right\|^2 = \sum_{j=k+1}^d \langle a, v_j \rangle^2$$

我们希望子空间 E 对全部数据 X 带来最小的均方损失, 由上式可知: 损失函数为 $\sum_{i=1}^n \|p_i - \pi(p_i)\|_2^2 = \|XV - XV_k\|_F^2 = \|XW\|_F^2$, 其中 V_k 是一个后 $d-k$ 列均为 0 的列正交矩阵, W 是一个 $d \times k$ 的列正交矩阵。实际上, $(V_k[1:k], W) = (v_1, \dots, v_d) =: V$. 所以问题转化为:

$$\begin{aligned} \min_{V_k \in \mathbb{R}^{d \times k}} \quad & -\|XV_k\|_F^2 \\ \text{s.t.} \quad & V_k^\top V_k = I_k \end{aligned}$$

直接使用拉格朗日乘子法, 可得

$$X^\top X v_i = \sigma_i^2 v_i.$$

即 $v_1, \dots, v_k$ 对应奇异值分解的右乘方阵 V 的前 k 列。

主成分分析的缺点包括:

1. 复杂度^{精度差}高。基于 QR 分解的奇异值分解有复杂度 $O(nd^2)$.

2. 作用于矩阵, 数值稳定性在维度高时难以保障。

3. 对数据多次读取, 不适合分布式计算。

隐私 privacy

3 相关研究

3.1 低秩近似

Theorem 3.1 (Eckart–Young–Mirsky). 对 $X \in \mathbb{R}^{n \times d}$, $\min_{\text{rank}(X_k) \leq k} \|X - X_k\|$ 仅在 $X_k = \sum_{i=1}^k \sigma_i \hat{u}_i \hat{v}_i^\top$ 时取到。此处的范数可以为谱范数或 Frobenius 范数, $\sigma_1, \dots, \sigma_d$ 是 X 从大到小排列的奇异值, $\hat{u}_i, \hat{v}_j$ 分别代表 U, V 的第 i 和第 j 列。

此外, 一些基于采样的随机算法也被开发出来, 参考 [1].

3.2 非负矩阵分解

对非负矩阵 $M \in \mathbb{R}^{n \times m}$, 求解

$$\begin{aligned} \min_{A, W \geq 0} \quad & \|AW - M\|_F \\ \text{s.t.} \quad & A \in \mathbb{R}^{n \times r}, W \in \mathbb{R}^{r \times m}. \end{aligned}$$

Example 3.2. M 可以表示 m 个 n 维数据, A 表示 r 个基向量, W 表示这些基向量的凸组合。

推荐系统曾经广泛采用这种算法。求精确解的复杂度为 $O(mn^{O(r^2)})$, 同样是 NP 完全问题。

References

- [1] D. P. Woodruff. Sketching as a tool for numerical linear algebra. *Foundations and Trends in Theoretical Computer Science*, 10(1–2):1–157, 2014.