

降维 (Dimension Reduction)

① PCA

② Random Projection 随机投影

③ Feature Selection 特征选取 (具体情况具体分析)

④ Manifold Learning ... / MDS / Auto-encoder...

PCA $\rightarrow$ 主成分分析

Lecture 7: 数据降维之 JL 变换

2024.3.12

Lecturer: 丁虎

Scribe: 沈俊杰

Johnson-Lindenstrauss (JL) 变换是一种用于高维数据的降维技术。其基本思想是将高维数据投影到一个低维的欧氏空间，同时保持数据点之间的距离。

1 JL 引理

JL transfor

 $k \sim \log n$

Theorem 1.1. JL 引理

对于任意给定的 $\epsilon \in (0, 1)$ 和 $n \in \mathbb{N}$ ，存在一个映射 $f: \mathbb{R}^d \rightarrow \mathbb{R}^k$ ，其中 $k = O(\frac{1}{\epsilon^2} \log n)$ ，使得对于任意两个向量 $x, y \in \mathbb{P} \subset \mathbb{R}^n$ ， $|\mathbb{P}| = n$ 有

$$(1 - \epsilon) \|x - y\|^2 \leq \|f(x) - f(y)\|^2 \leq (1 + \epsilon) \|x - y\|^2 \quad (1)$$

存在性

这个引理的含义是，对于任意的两个向量 x, y ，在映射后的空间中，它们的距离与原空间中的距离保持在 $(1 - \epsilon, 1 + \epsilon)$ 的范围内。

Definition 1.2. JL 变换

构造一个矩阵 $B \in \mathbb{R}^{k \times d}$

f 映射后距离差不大

$$f(u) = B \cdot u \quad (2)$$

如果 f 满足 JL 引理中的条件，那么称 B 为 JL 变换。

很自然的，我们需要考虑如何构造这样的矩阵 B

2 构造 JL 变换的方法

一种简单的构造方法是，通过高斯分布进行构造： $B = \frac{1}{\sqrt{k}} \cdot A$ ，其中 $a_{ij} \sim N(0, 1)$

现在我们需要证明的是，这样构造的 B 是一个 JL 变换。注意到矩阵计算的性质，实际上证明 JL 引理成立仅需要证明对于 $\forall x \in \mathbb{X}$ ，有：

$$(1 - \epsilon) \|x\|^2 \leq \|B \cdot x\|^2 \leq (1 + \epsilon) \|x\|^2 \quad (3)$$

1

trivial Gaussian random matrix

把 C_n^2 个点看成 $O(n^2)$ 个向量. $x-y \in \mathbb{R}^d$ ☆

其中 $\mathbb{X}$ 中的元素集合 $\mathbb{P}$ 元素的点对组合, $|\mathbb{X}| = \binom{n}{2}$ 我们可以考虑证明对某一个 x 作证明, 然后通过 union bound 的技术推广到整个集合。

$y = \frac{1}{\sqrt{k}} A \cdot x$, 因为随机矩阵 B 的引入, y 是一个随机变量, 自然的, 我们应当考虑他的性质, 比如 $E[y^T y]$ 。

Lemma 2.1.

$$y = B \cdot x = \frac{1}{\sqrt{k}} A \cdot x$$

$$E[\|y\|^2] = \|x\|^2$$

Proof.

$$A = \begin{bmatrix} A_1 \\ A_2 \\ \vdots \\ A_k \end{bmatrix}$$

$$E[\|y\|^2] = \frac{1}{k} E\left[\sum_{j=1}^k (A_j x)^2\right]$$

$$= \frac{1}{k} \sum_{j=1}^k E[(A_j x)^2]$$

$$= \frac{1}{k} \sum_{j=1}^k E\left[\sum_{i=1}^d (A_{ji} x_i)^2\right]$$

$$= \frac{1}{k} \sum_{j=1}^k E\left[\sum_{i/i'}^d A_{ji} A_{ji'} x_i x_{i'}\right]$$

$$\forall i \neq i' \quad E[A_{ji} A_{ji'}] = E[A_{ji}] E[A_{ji'}] = 0 \quad (\text{独立性})$$

$$\Rightarrow E[(A_j x)^2] = \sum_{i=1}^d E[A_{ji}^2 x_i^2]$$

$$= \sum_{i=1}^d x_i^2$$

$$\therefore E[\|y\|^2] = \|x\|^2$$

$$E[A^2] = \text{Var}(x) + (E[A])^2 = 1$$

交叉项为0

$$A_{ji} \sim N(0, 1)$$

A_{ji} 为 A 中元素 a_{ji}

□

仅仅期望, 是不够的, 当然, 我们可以通过根据期望相关的不等式得到一些相对粗糙的结论, 不在此赘述。我们考虑 $\text{Prob}[\|y\|^2 \geq (1 + \epsilon)\|x\|^2]$, 此即 JL 引理的右半边形式。

简单化简, Prob 内的公式可化为:

$$(k \times d)$$

2

$$A = \begin{bmatrix} A_1 \\ \vdots \\ A_k \end{bmatrix}$$

$$A_j \quad 1 \times d \quad x: d \times 1$$

$|A_k|$

$|A_k|$

$$\frac{\|Ax\|^2}{\|x\|^2} \geq (1 + \epsilon)k$$

考虑左边:

$$\begin{aligned} \frac{\|Ax\|^2}{\|x\|^2} &= \sum_{j=1}^k \frac{(A_j \cdot x)^2}{\|x\|^2} \\ &= \sum_{j=1}^k z_j^2 \end{aligned}$$

$z_j = A_j \frac{x}{\|x\|^2}$

相当于每个 A_{ji} 归一化分量

χ^2 分布

$$z_j = \frac{A_j \cdot x}{\|x\|} = \sum_{i=1}^d A_{ji} \frac{x_i}{\|x\|}$$

注意到 $z_j \sim N(0, 1)$, 因此我们考虑 $\text{Prob} \left[\sum_{j=1}^k z_j^2 \geq (1 + \epsilon)k \right]$

$$\text{Prob} \left[\sum_{j=1}^k z_j^2 \geq (1 + \epsilon)k \right] = \text{Prob} \left[\exp(\lambda \sum_{j=1}^k z_j^2) \geq \exp(\lambda(1 + \epsilon)k) \right]$$

e 指数

$$\leq \frac{1}{\exp(\lambda(1 + \epsilon)k)} E \left[\exp(\lambda \sum_{j=1}^k z_j^2) \right]$$

(Markov Inequality)

$$\begin{aligned} E[e^{\lambda z_j^2}] &= \int_{-\infty}^{+\infty} e^{\lambda z_j^2} \frac{1}{\sqrt{2\pi}} e^{-\frac{z_j^2}{2}} dz \\ &= \frac{1}{\sqrt{1-2\lambda}} \end{aligned}$$

$$= \frac{1}{\exp(\lambda(1 + \epsilon)k)} \prod_{j=1}^k E[e^{\lambda z_j^2}]$$

$$= \frac{1}{\exp(\lambda(1 + \epsilon)k)} \prod_{j=1}^k \frac{1}{\sqrt{1-2\lambda}}$$

($z_j^2 \sim \chi^2(1)$ 矩母函数)

$$= \frac{1}{\exp(\lambda(1 + \epsilon)k)} \frac{1}{(1-2\lambda)^{k/2}}$$

$$= ((1 + \epsilon)e^{-\epsilon})^{k/2}$$

$$\left(\text{let } \lambda = \frac{\epsilon}{2(1 + \epsilon)} \right)$$

$$\leq e^{-\frac{k}{4}(\epsilon^2 - \epsilon^3)}$$

对于另一边不等式, 我们有类似的推导, 最终得到:

$$\text{Prob} [\|y\|^2 \geq (1 + \epsilon)\|x\|^2] \leq e^{-\frac{k}{4}(\epsilon^2 - \epsilon^3)}$$

$$\text{Prob} [\|y\|^2 \leq (1 - \epsilon)\|x\|^2] \leq e^{-\frac{k}{4}(\epsilon^2 + \epsilon^3)}$$

$$\Rightarrow \text{Prob} [\|y\|^2 \in (1 \pm \epsilon)\|x\|^2] \geq 1 - 2e^{-\frac{k}{4}(\epsilon^2 - \epsilon^3)}$$

一共有 $\binom{n}{2} = \theta(n^2)$ 个点, 我们可以通过 union bound 的技术, 若要得到常数概率, 我们需要 $k = \theta(\frac{1}{\epsilon^2} \log n)$ 即可, 通过反解下式得到。

一个向量违反概率
为 $e^{-\frac{k}{4}(\epsilon^2 - \epsilon^3)}$

3

n^2 个

算一个
+ 概率

$$\frac{k}{4}(\epsilon^2 - \epsilon^3) = \frac{1}{2}$$

$$k(\epsilon^2 - \epsilon^3) = 2 \log n$$

$$\Rightarrow k = \Theta(\frac{1}{\epsilon^2} \log n)$$

$$e^{-\frac{k}{4}(\epsilon^2 - \epsilon^3)} = \theta(\frac{1}{n^2})$$

Remark 2.2. 关于概率的一些结算，请牢记证明中引入的随机变量是 $A = (A_{ij})$ ，一切随机性由其得到。

Remark 2.3. Key idea:

$$\|y\|^2 = y_1^2 + y_2^2 + \dots + y_k^2$$

$$= \frac{1}{k}((A_1x)^2 + (A_2x)^2 + \dots + (A_kx)^2) \quad (\text{每一项都是对}\|x\|^2\text{的估计})$$

$$A_1x = A_{11}x_1 + A_{12}x_2 + \dots + A_{1d}x_d$$

不妨假设 x 是单位向量，那么 $(A_1x)^2$ 以一定概率接近 1 即可

3 JL 变换 v.s. PCA

Table 1: JL 变换 v.s. PCA

	JL 变换	PCA
Running time	$\theta(nd \frac{\log n}{\epsilon^2})$	$\theta(nd^2)$
Data	Data Oblivious(可应用于流数据，并行)	Data Dependent

JL: 左乘一个矩阵即可

Remark 3.1. 这里的 JL 变换时间复杂度中， n 来自于对于 n 个数据点依次进行 JL 变换，但理论上，我们不需要知道所有点就可以进行 JL 变换，但 PCA 做不到这一点，PCA 需要对 n 个数据点一起处理。这也是所谓 Data Oblivious 的意思。

4 其他 JL 变换

基于 Gaussian 的矩阵 A 是稠密的，如果我们想要一个稀疏的随机矩阵，是否有办法呢？答案是肯定的。事实上，有一些别的构造方法，不依赖于 Gaussian。例如：

$$A_{ij} = \begin{cases} +1 & \sim 50\% \\ -1 & \sim 50\% \end{cases} \quad A_{ij} = \sqrt{3} \begin{cases} +1 & \sim 1/6 \\ 0 & \sim 2/3 \\ -1 & \sim 1/6 \end{cases}$$

证明 $P(\|y\|^2 \geq (1-\epsilon)\|x\|^2)$

可参考 [1]

针对 $d > 2^k$ 的情况，即原维度远大于降维后的维度时，我们有一个技巧可以减低计算复杂度。

以下面的随机矩阵构造为例。

$$A_{ij} = \begin{cases} +1 & \sim 50\% \\ -1 & \sim 50\% \end{cases}$$

此时计算 $B \cdot x = H_k \cdot C \cdot x$ ，其中 C 是一个稀疏矩阵， H_k 的每一列是一个可能的组合，即：

$B \cdot (k \times d)$

$$H_k = [h_1 \ h_2 \ \cdots \ h_{2^k}], \quad H \in \mathbb{R}^{k \times 2^k}$$

$$C = \begin{bmatrix} 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 1 \end{bmatrix}, \quad C \in \mathbb{R}^{2^k \times d}$$

C 的每一列是一个选择向量，上面给出一个例子，对 C 的要求是每列有且仅有一个 1，其余为 0。根据矩阵乘法的性质，我们可以得到计算开销变为 $\theta(d)$ ，相比原有的 $\theta(k \cdot d)$ 。

5 Fast JL 变换

Fast JL transform (2009)

回到我们的问题，我们希望有这样一个 JL 变换 $x \rightarrow Ax$ ，我们希望 A 是一个稀疏矩阵，但同时希望 $\|Ax\|^2$ 与 $\|x\|^2$ 大概率接近。

我们的构造方法通过矩阵旋转来实现矩阵的稀疏化。

5.1 构造方法

$k \times d \quad d \times d \quad d \times d$

$$\Phi = P \cdot H \cdot D$$

P:

$$P \in \mathbb{R}^{k \times d}, \quad p_{ij} = \begin{cases} N(0, \frac{1}{q}) & \sim q \\ 0 & \sim 1 - q \end{cases}, \quad q = \min\{\theta(\frac{\log^2 n}{d}), 1\}$$

+值

$x \rightarrow (\Phi) \rightarrow$
稀疏, dense.

$d \rightarrow k$

复杂度 ↓↓

$$\log^2 n \ll d$$

可以计算 P 的稀疏程度:

非零元素期望

$$\#\{\text{non-zero of } P\} = k \cdot d \cdot \underbrace{q}_{\substack{\text{个数} \\ \text{概率}}} = k \log^2 n \ll kd$$

H:

$H \in \mathbb{R}^{d \times d}$: H 是归一化的 Hadamond 矩阵

Hadamond 矩阵的维度是 2 的幂次方, 对于 $2^{k-1} < d < 2^k$, 将剩余维度补 0 即可。Hadamond 矩阵满足 $H_d^T H_d = dI$, 即 Hadamond 矩阵是正交矩阵。使用归一化的 Hadamond 矩阵后 $H^T H = I$

Hadamond 矩阵满足递推关系:

$$H_{2^k} = \begin{bmatrix} H_{2^{k-1}} & H_{2^{k-1}} \\ H_{2^{k-1}} & -H_{2^{k-1}} \end{bmatrix},$$

$$H = \frac{1}{\sqrt{d}} H_d$$

任意两行/两列 正交 内积为 0 等距变换 (旋转/对称)

根据该递推式的性质, Hadamond 矩阵乘法可以进行加速:

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \quad x_1, x_2 \in \mathbb{R}^{d/2}, \quad Hx = \frac{1}{\sqrt{d}} \begin{bmatrix} H_{d/2} \cdot x_1 + H_{d/2} \cdot x_2 \\ H_{d/2} \cdot x_1 - H_{d/2} \cdot x_2 \end{bmatrix}$$

$$T(d) = 2T(d/2) + \theta(d) \Rightarrow T(d) = \theta(d \log d) \quad d^2 \rightarrow d \log d$$

D: D 是一个对角方阵, 只有在对角线上的元素有非零值, 且是 ± 1 , 满足:

$$D \in \mathbb{R}^{d \times d}, \quad D_{ii} = \begin{cases} +1 & \sim 0.5 \\ -1 & \sim 0.5 \end{cases}$$

5.2 启发性展示

Fast JL 变换的证明较为复杂, 相关内容的证明可以参考 [2] 后续助教的习题课也会有所说明。我们在此给出一些启发性的说明, 并进行计算复杂度分析。

Fast JL 变换构造的变换中, 可以分为两部分: P 和 (H · D)。前者的构造和 n 有关, 而后者与 n 无关, 其计算可以通过预处理得到。

前者的作用和前文中的 A 一致, 可以证明, 如果 x 满足光滑性, 那么无须后者也可成立。相应的, 反例就是 x 向量的多数维度, 特别的, d-1 个维度都为 0, 只有一个维度非零, 那么此时 P 的多数变量未参与计算 (有效的估计数变少), 这是我们不希望的。而后者的作用就是让 x 以较大概率变得稠密 (无论其原本是稀疏还是稠密), 因此两者结合, 会取得较好的效果。计算复杂度如下, 注意, 最外的 n 同样也是对于 n 个点应用变换导致的。 $\theta(d \log d)$

Hadamond 变换

来自于 $(H \cdot D)$ 的计算, $\theta(|P|)$ 来自于 $P \cdot (*)$ 的计算, $|P|$ 指矩阵 P 的非零元素个数。 $\tilde{\theta}$ 表示忽略次线性项中的指数项。

$$\begin{aligned}
 T(d, n) &= (\theta(d \log d) + \theta(|P|))n \\
 &= \theta(d \log d + k \cdot d \cdot q) \cdot n \quad \star \\
 &= \theta(d \log d + \frac{\log^3 n}{\epsilon^2}) \cdot n \quad k \log^2 n \\
 &= \tilde{\theta}(d + \frac{1}{\epsilon^2})n \quad \left(k \sim \frac{\log n}{\epsilon^2} \right) \quad \text{降阶}
 \end{aligned}$$

Handwritten notes: $k \cdot d \cdot q \ll kd$, $\log$ 全部忽略

相比于先前 JL 变换的复杂度 $\theta(\frac{nd}{\epsilon^2} \log n) = \tilde{\theta}(\frac{d}{\epsilon^2})n$, 有显著的加速效果。

References

- Handwritten note:* 引入 $q = \frac{\log^2 n}{d}$
- [1] D. Achlioptas. Database-friendly random projections: Johnson-lindenstrauss with binary coins. *Journal of Computer and System Sciences*, 66(4):671–687, 2003. Special Issue on PODS 2001.
 - [2] N. Ailon and B. Chazelle. Approximate nearest neighbors and the fast johnson-lindenstrauss transform. In *Symposium on the Theory of Computing*, 2006.

$$\begin{aligned}
 d \cdot \frac{1}{\epsilon^2} &\sim d + \frac{1}{\epsilon^2} \\
 \Rightarrow \text{次} &\longleftrightarrow \text{次}
 \end{aligned}$$